

Double Machine Learning

機械学習


川田恵介
東京大学

keisukekawata@iss.u-tokyo.ac.jp

2025-12-08

1 復習

1.1 単純比較: 専門職 VS 非専門職



1.2 バランス後の比較

- 比較分析: $E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$ の推定
- 本スライド: 以下を想定

$$E[Y \mid D, X] = \underbrace{\beta_D \times District}_{D \text{に関する部分}}$$

$$\underbrace{+\beta_0 + \beta_1 \times X_1 + \beta_2 \times X_2 + \dots}_{X \text{に関する部分}}$$

- X の偏り/影響を排除し、 Y と D の関係性を推定

1.3 予測の直接活用

- 二重選択法 (LASSO によって、 X のなから重要な変数を選ぶ) を紹介
- LASSO よりも性能の良い予測モデルの推定方法 (Stacking) や 汎用性のある AI が活用できないか？
 - ▶ 古典的なアイデア (Varian, 2014) を改良した手法を紹介
 - ▶ 高性能な予測モデルを直接的に活用できる

1.4 汎用 AI(大規模言語モデル)の活用

- Chat-GPT 🗨️ などに、直接質問する
- 専門職/非専門職間での平均賃金格差を推定したい
 - ▶ X = 年齢、学歴
- 🧑 : 30 歳、大卒、専門職の年収は？
 - ▶ 🗨️ : 700 万円
- 🧑 : 30 歳、大卒、非専門職の年収は？
 - ▶ 🗨️ : 500 万円
- 🧑 : 700 万円 - 500 万円 = 200 万円

1.5 自作 AI の活用

```
library(tidyverse)

data("CPS1985", package = "AER")

data <- mutate(
  CPS1985,
  D = if_else(
    occupation == "technical",
    1,
    0
  )
)

Y <- data$wage
```

```
X <- select(
  data,
  D,
  age,
  education)
```

1.6 価格予測 AI の推定

```
library(SuperLearner)

model = SuperLearner(
  Y = Y,
  X = X,
  SL.library = c("SL.lm", "SL.ranger")
)
```

1.7 自作 AI による推定

```
predict(model, tibble(D = 1, age = 30, education = 16))$pred
```

```
      [,1]
[1,] 11.47646
```

```
predict(model, tibble(D = 0, age = 30, education = 16))$pred
```

```
      [,1]
[1,] 10.10575
```

- 差は 1.37

1.8 問題点

- 価格予測 AI の性能に、推定結果が強く依存
 - ▶ 汎用 AI や Stacking などを持ちいた自作 AI も、母平均を十分に近似できていない可能性が高い

2 二つの AI を活用

2.1 ダブルチェック

- 「(自作した) Y を予測する AI 🤖 と D を予測する AI 🤖 にダブルチェックさせる」が有効
- 🧑: 大学卒、30 歳の賃金は？

- ▶ 🚗 : 600 万円
- 🧑 : 大学卒、30 歳の専門職の割合は？
 - ▶ 🧑 : 35%

2.2 予測誤差同士の回帰

- データ上のすべての事例について、予測値を計算した後に、
- $(Y - \hat{Y})$ の予測値) を $(D - \hat{D})$ の予測値) で OLS 推定する

2.3 手順

1. データの事例について、 Y/D の予測値を算出する
 - 本講義では、Stacking 法を用いて自作 AI を作るアプローチを推奨
 - ▶ 汎用 AI の活用も議論されている (Engh and Aronow, 2025)
2. $(Y - \hat{Y})$ の予測値) を $(D - \hat{D})$ の予測値) で OLS 推定する

2.4 実装

- 専用のパッケージを利用した方が、安全に実装できる
- ここでは ddml package を利用
 - ▶ doubleml package も有力な選択肢

2.5 実装

```
library(tidyverse)
library(ddml)

data("CPS1985", package = "AER")

data <- mutate(
  CPS1985,
  D = if_else(
    occupation == "technical",
    1,
    0
  )
)

Y <- data$wage

D <- data$D

X <- model.matrix(
```

```
~ 0 + age + education + gender + ethnicity,  
data)
```

2.6 実装

```
model <- ddml::ddml_plm(  
  y = Y,  
  D = D,  
  X = X,  
  learners = list(  
    list(fun = ols),  
    list(fun = mdl_ranger)  
  ),  
  shortstack = TRUE,  
  silent = TRUE  
)
```

2.7 実装

```
summary(model)
```

PLM estimation results:

, , nnls

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.0103	0.193	-0.0535	0.9573
D_r	1.1234	0.649	1.7299	0.0836

2.8 推定値の性質

- いくつかの条件のもとで、バランス後の平均差について、信頼できる信頼区間を計算できる
- 代表的な仮定は、
 - ▶ 事例数が無限大に増加すると、予測モデルと条件付き母平均が一致する
 - ▶ 事例数の増加によって、予測モデルと条件付き母平均の乖離が減少する
 - 減少の速度が一定以上 ($n^{1/4}$ 以上の速度で減少する)
 - ▶ Stacking などの高品質な予測モデルの推定が期待できる方法で、二つの予測モデルは推定されている

2.9 交差推定の活用

- Stacking を構成するアルゴリズムの数が極端に多い場合、追加的なサンプル分割が必要 (Ahrens et al., 2025)
 - 経済学の多くの応用においては、問題なく活用可能
- もし Random Forest などのみを使用するのであれば、交差推定は必須

3 補論: 詳細

3.1 Partial linear model (Robinson, 1988)

- 推定対象 β_D を以下の部分線型モデルで定義する

$$E[Y | D, X] = \beta_D \times D + \underbrace{f(X)}_{X \text{ についての複雑なモデル}}$$

- 以下のように書き換えることもできる

$$Y = \beta_D \times D + f(X) + \underbrace{U}_{E[U|D,X]=E[U|X]=0} \quad (1)$$

3.2 書き換え

- Equation 1 は以下のように書き換えられる

$$E[Y | X] = \beta_D \times E[D | X] + f(X) + \underbrace{E[U | X]}_{=0}$$

- Equation 1 から引くと

$$Y - E[Y | X] = \beta_D \times [D - E[D | X]] + \underbrace{U}_{E[U|D,X]=0}$$

3.3 含意

- 部分線型モデルは、以下の手順で推定できる
 - $E[Y | X]/E[D | X]$ を推定し、 Y, D から引く
 - $Y - E[Y | X]$ と $D - E[D | X]$ を OLS で回帰する
- $E[Y | X]/E[D | X]$ は、 Y/D の予測モデルとして推定できる

3.4 性質

- もし、 $E[Y | X]/E[D | X]$ を正確に推定できたのであれば、以下を最小化することで、 β_D は推定できる

$$\min \sum (Y - E[Y | X] - \beta_D \times (D - E[D | X]))^2$$

- 以下の一階条件を満たす β_D を探せば良い

$$0 = \sum (D - E[D | X]) \\ \times (Y - E[Y | X] - \beta_D \times (D - E[D | X]))$$

3.5 性質

- 実際には、 $E[Y | X]/E[D | X]$ を正確に推定することは不可能
 - $E[Y | X]/E[D | X]$ の推定誤差が、 β_D の推定結果に与える影響は”小さい” (Chernozhukov et al., 2022)

3.6 例

- $E[Y | X]$ の推定結果が 0.1 だけ上振れたとすると
- β_D の推定式は、

$$0 = \sum (D - E[D | X]) \\ \times (Y - E[Y | X] - 0.1 - \beta_D \times (D - E[D | X]))$$

3.7 例

- $$= \sum (D - E[D | X]) \\ \times (Y - E[Y | X] - \beta_D \times (D - E[D | X]))$$

$$- \underbrace{\sum 0.1 \times (D - E[D | X])}_{\beta_D \text{ への影響}}$$

3.8 例: Double check

- $E[D | X]$ が正確に推定できており、事例数が十分にあると

$$\underbrace{\sum 0.1 \times (D - E[D | X])}_{\beta_D \text{ への影響}} \simeq 0$$

- もちろん $E[D | X]$ の正確な推定は難しいが、
 - $E[Y | X]/E[D | X]$ の推定を同時に大きく失敗しない限り、 β_D の推定結果は大きな影響を受けない

3.9 Reference

Bibliography

Ahrens, A. et al. (2025) “Model averaging and double machine learning,” Journal of Applied Econometrics, 40(3), pp. 249–269.

Chernozhukov, V. et al. (2022) “Locally robust semiparametric estimation,” *Econometrica*, 90(4), pp. 1501–1535.

Engh, C. and Aronow, P. (2025) “Using LLMs to Directly Guess Conditional Expectations Can Improve Efficiency in Causal Estimation,” arXiv preprint arXiv:2510.09684 [Preprint].

Robinson, P.M. (1988) “Root-N-consistent semiparametric regression,” *Econometrica*, pp. 931–954.

Varian, H.R. (2014) “Big data: New tricks for econometrics,” *Journal of economic perspectives*, 28(2), pp. 3–28.